

Ejercicio 1

$$a) \begin{cases} \min \|x\|^2 \\ \text{st } \sum_i x_i = 1 \end{cases}$$

Escribimos el Lagrangeano del problema

$$L(x, \lambda) = \|x\|^2 + \lambda (\sum_i x_i - 1)$$

Calculamos los gradientes de L

$$\nabla_x L(x, \lambda) = 2x + \lambda \mathbf{1} \quad \rightarrow \text{vector de 1's}$$

$$\nabla_\lambda L(x, \lambda) = \sum_i x_i - 1$$

Iguálamos a 0

$$\Rightarrow \begin{cases} 2x + \lambda \mathbf{1} = 0 & (1) \\ \sum_i x_i = 1 & (2) \end{cases}$$

De (1) tenemos que $x_i = -\frac{\lambda}{2}$

Introducimos lo anterior en (2)

$$\Rightarrow \sum_{i=1}^n \frac{-\lambda}{2} = 1 \Rightarrow -n \frac{\lambda}{2} = 1 \Rightarrow \lambda = -\frac{2}{n}$$

$$\Rightarrow x_i = -\frac{(-\frac{2}{n})}{2} = \frac{1}{n} \Rightarrow \boxed{\bar{x}_i = 1/n}$$

Verifiquemos la cond. de 2^{da} orden:

$$\nabla_{xx} L = 2 \text{Id} > 0 \Rightarrow \bar{x}_i = 1/n \text{ es la solución del problema}$$

$$b) \min \sum x_i \\ \text{st } \|x\|^2 = 1$$

El Lagrangeano $L(x, \lambda)$

$$L(x, \lambda) = \sum x_i + \lambda (\|x\|^2 - 1)$$

$$\nabla_x L(x, \lambda) = \mathbf{1} + 2\lambda x$$

$$\nabla_\lambda L(x, \lambda) = \|x\|^2 - 1$$

Iguálamos los ∇ a 0

$$\begin{cases} \mathbf{1} + 2\lambda x = 0 & (1) \\ \|x\|^2 = 1 & (2) \end{cases}$$

$$\text{De (1): } x_i = \frac{-1}{2\lambda}$$

Introduciendo en (2)

$$\sum x_i^2 = \sum \left(\frac{-1}{2\lambda} \right)^2 = \frac{n}{4\lambda^2} = 1 \Rightarrow \lambda = \pm \frac{\sqrt{n}}{2}$$

$$\Rightarrow x_i = \frac{-1}{2 \left(\pm \frac{\sqrt{n}}{2} \right)} = \mp \frac{1}{\sqrt{n}}$$

Verifiquemos la condición de 2^{do} orden:

$$\nabla_{xx} L(\bar{x}, \bar{\lambda}) = 2\lambda Id = \mp 2 \frac{\sqrt{n}}{2} Id = \mp \sqrt{n} Id$$

$$\nabla_{xx} L(\bar{x}, \bar{\lambda}) > 0 \Leftrightarrow \mp \sqrt{n} > 0 \Leftrightarrow \text{los}$$

$$\left| \bar{x}_i = -\frac{1}{\sqrt{n}} \right. \text{ son solución}$$

La solución óptima del problema es

$$\boxed{\bar{x}_i = -1/\sqrt{n}}$$

$$c) \begin{cases} \min \|x\|^2 \\ \text{st } x^T Q x = 1 \end{cases} \quad \text{con } Q \geq 0 \text{ y } Q^T = Q$$

El Lagrangiano del problema es:

$$L(x, \lambda) = \|x\|^2 + \lambda (x^T Q x - 1)$$

Sus gradientes son:

$$\nabla_x L(x, \lambda) = 2x + 2\lambda Qx$$

$$\nabla_\lambda L(x, \lambda) = x^T Q x - 1$$

Como $\nabla L(\bar{x}, \bar{\lambda}) = 0$ es una condición necesaria para que \bar{x} sea óptimo, busquemos el \bar{x} que la cumple

$$\Rightarrow \nabla L(\bar{x}, \bar{\lambda}) = 0 \Leftrightarrow \begin{cases} \bar{x} + \bar{\lambda} Q \bar{x} = 0 \\ \bar{x}^T Q \bar{x} - 1 = 0 \end{cases} \Leftrightarrow \begin{cases} Q \bar{x} = -\frac{1}{\bar{\lambda}} \bar{x} & (1) \\ \bar{x}^T Q \bar{x} = 1 & (2) \end{cases}$$

Llamemos α_i al i -ésimo valor propio de Q . De la ec. (1) sabemos que \bar{x} deberá ser un v.p. de Q asociado a $\alpha_i = -\frac{1}{\bar{\lambda}}$

Si introducimos (1) en (2) se tiene:

$$\bar{x}^T Q \bar{x} = \bar{x}^T \left(-\frac{1}{\bar{\lambda}} \bar{x} \right) = -\frac{1}{\bar{\lambda}} \|\bar{x}\|^2 = 1$$

$$\Rightarrow \|\bar{x}\|^2 = -\bar{\lambda} = \frac{1}{\alpha_i}$$

Por lo tanto, sabemos que \bar{x} además de ser v.e.p. de Q deberá tener norma $\frac{1}{\sqrt{\alpha}}$.

Sabemos que el problema tiene mínimo porque la función es convexa. Es posible buscar cuál de todos los candidatos optimiza el problema

Lo anterior lleva a que el \bar{x} que optimiza el problema sea el vector propio asociado al valor propio más grande(a) de Q y que además su norma sea $\frac{1}{\sqrt{\alpha}}$

Ejercicio 2

$$(P) \begin{cases} \min \sum_i \alpha_i x_i & \text{con } \alpha_i \geq 0 \\ \text{s.t. } \prod_i x_i^{\alpha_i} = 1 & \text{y } \sum_i \alpha_i = 1 \\ x_i > 0 \quad \forall i = 1, \dots, n \end{cases}$$

Tomemos que $y_i = \ln x_i \Rightarrow x_i = e^{y_i}$

Apliquemos \ln a ambos lados de la restricción

$$\Rightarrow \ln\left(\prod_i x_i^{\alpha_i}\right) = \ln(1)$$

$$\Rightarrow \sum_i \alpha_i \ln x_i^{\alpha_i} = 0$$

$$\Rightarrow \boxed{\sum_i \alpha_i y_i = 0}$$

Aplicar \ln a ambos lados y que la restricción sea la misma es válido ya que \ln es monótono creciente.

Apliquemos el cambio de variable $x_i = e^{y_i}$ sobre la función a minimizar:

$$\sum_i \alpha_i x_i = \sum_i \alpha_i e^{y_i}$$

Notar que si $x_i > 0$ siempre es válido tomar $y_i = \ln x_i$

Un problema equivalente en términos de y_i es:

$$\begin{cases} \min \sum_i \alpha_i e^{y_i} = f(y) \\ \text{st } \sum \alpha_i y_i = g = h(y) \end{cases} \quad (Q)$$

Si hallamos los y_i óptimos, luego tenemos los x_i óptimos como $x_i = e^{y_i}$

El Lagrangeano de (Q) es:

$$L(y, \lambda) = \sum_i \alpha_i e^{y_i} + \lambda \sum_i \alpha_i y_i$$

su gradiente respecto a y es:

$$\nabla_y L(y, \lambda) = \begin{pmatrix} \alpha_1 (e^{y_1} + \lambda) \\ \alpha_2 (e^{y_2} + \lambda) \\ \vdots \\ \alpha_n (e^{y_n} + \lambda) \end{pmatrix}, \text{ Es decir } (\nabla_y L)_j = \alpha_j (e^{y_j} + \lambda)$$

Notar que $\nabla_y L = 0 \Leftrightarrow e^{y_i} = -\lambda \quad \forall i$
 $\Rightarrow \boxed{y_i = \ln(-\lambda)}$

El gradiente respecto a λ es:

$$\nabla_\lambda L(y, \lambda) = h(y) = \sum_i \alpha_i y_i = \sum_i \alpha_i \ln(-\lambda)$$

Ver que $= \ln(-\lambda) \sum_i \alpha_i = \ln(-\lambda)$

Notar que $\nabla_\lambda L = 0 \Leftrightarrow \boxed{\lambda = -1}$

si $\lambda = -1 \Rightarrow \boxed{\bar{y}_i = 0}$

Verifiquemos la condicion de segundo orden:

$$\nabla_{yy} L(y, \lambda) = \begin{pmatrix} \alpha_1 e^{y_1} & 0 & \dots & 0 \\ 0 & \alpha_2 e^{y_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \alpha_n e^{y_n} \end{pmatrix}$$

$$\nabla_{yy} L(\bar{y}, \lambda) = \begin{pmatrix} \alpha_1 & & & \\ & \alpha_2 & & \\ & & \alpha_3 & \\ & & & \ddots \\ 0 & & & & \alpha_n \end{pmatrix}$$

$$\nabla_{yy} L(\bar{y}, \lambda) > 0 \Leftrightarrow \alpha_i > 0 \quad \forall i$$

Perotenenos que $\alpha_i > 0 \quad \forall i \Rightarrow \nabla_{yy}$ es definido positivo
 $\Rightarrow \bar{y}_i = 0$ es minimo.

Si $\bar{y}_i = 0$ es minimo de (Q) $\Rightarrow \boxed{\bar{x}_i = 1 \text{ es minimo de (P)}}$

Para probar que $\prod_i x_i^{\alpha_i} \leq \sum_i \alpha_i x_i$ es necesario resolver el siguiente problema de optimización:

$$\begin{cases} \min \sum \alpha_i x_i = f(x) \\ \text{st. } \prod x_i^{\alpha_i} = K & (B) \\ x_i > 0 \quad \forall i=1, \dots, n. \end{cases}$$

Este problema se resuelve de forma análoga a (P) y la solución óptima se obtiene en

$$\boxed{\bar{x}_i = K} \text{ y } \boxed{f(\bar{x}) = \sum \alpha_i K = K}$$

Supongamos que para un x dada se cumple

$$\prod_i x_i^{\alpha_i} = \phi$$

Sabemos $\sum \alpha_i x_i$ será como muy chica ϕ

$$\Rightarrow \prod_i x_i^{\alpha_i} = \phi \leq \sum_i \alpha_i x_i$$

$$\Rightarrow \boxed{\prod_i x_i^{\alpha_i} \leq \sum_i \alpha_i x_i}$$

Ejercicio 3

$$\begin{cases} \min \sum_{i=1}^m \|x - a_i\|^2 = f(x) & \text{con } \hat{a} = \frac{1}{m} \sum a_j \\ \text{st } \|x\|^2 = 1 \end{cases}$$

El lagrangeano del problema es:

$$L(x, \lambda) = \sum_{j=1}^m \|x - a_j\|^2 + \lambda (\|x\|^2 - 1)$$

Calculemos el gradiente de L

$$\begin{aligned} * \nabla_x L(x, \lambda) &= 2 \sum_{j=1}^m (x - a_j) + 2\lambda x \\ &= 2 \sum_{j=1}^m x - 2 \sum_{j=1}^m a_j + 2\lambda x \\ &= 2mx - 2\hat{a} + 2\lambda x = 2[x(m+\lambda) - \hat{a}] \end{aligned}$$

$$\nabla_x L(x, \lambda) = 0 \Rightarrow \boxed{x = \frac{\hat{a}}{m+\lambda}}^{(1)} \text{ si } \hat{a} \neq 0$$

$$* \nabla_\lambda L(x, \lambda) = \|x\|^2 - 1$$

$$\nabla_\lambda L(x, \lambda) = 0 \Leftrightarrow \boxed{\|x\|^2 = 1} \Rightarrow \sum_{i=1}^m x_i^2 = 1$$

Junfando ambas condiciones se tiene:

$$\sum x_i^2 = \sum \left(\frac{\hat{a}_i}{m+\lambda} \right)^2 = \frac{1}{(m+\lambda)^2} \sum \hat{a}_i^2 = \frac{1}{(m+\lambda)^2} \|\hat{a}\|^2 = 1$$

$$\frac{1}{(m+\lambda)^2} \|\hat{a}\|^2 = 1 \Leftrightarrow m+\lambda = \pm \|\hat{a}\|$$

$$\Rightarrow \bar{\lambda} = -m \pm \|\hat{a}\|$$

Vuelvo a introducir en (1)

$$\Rightarrow x = \frac{\hat{a}}{m - m \pm \|\hat{a}\|} = \pm \frac{\hat{a}}{\|\hat{a}\|}$$

$$\Rightarrow \boxed{\bar{x} = \pm \frac{\hat{a}}{\|\hat{a}\|}} \quad \bar{\lambda} = -m$$

Verifico la condición de 2º orden:

$$\nabla_{xx} L(x, \lambda) = 2(m+\lambda) \text{Id}$$

$$\nabla_{xx} L(\bar{x}, \bar{\lambda}) > 0 \Leftrightarrow \underline{m + \bar{\lambda} > 0}$$

Veamos cuando se cumple esta condición:

$$m + \bar{\lambda} = \begin{cases} m + (-m + \|\hat{a}\|) = \|\hat{a}\| > 0 & \text{si } \hat{a} \neq 0 \\ m + (-m - \|\hat{a}\|) = -\|\hat{a}\| < 0 & \text{si } \hat{a} \neq 0 \end{cases}$$

Lo anterior implica que $\begin{cases} \bar{x} = \frac{\hat{a}}{\|\hat{a}\|} & \text{es mínimo} \\ \bar{x} = -\frac{\hat{a}}{\|\hat{a}\|} & \text{es máximo} \end{cases}$

La solución del problema es

$$\boxed{\bar{x} = \frac{\hat{a}}{\|\hat{a}\|}}$$

¿Qué pasa si $\hat{a}=0$?

Recordar que se debía cumplir

$$\left. \begin{array}{l} x(m+\lambda) - \hat{a} = 0 \\ \|x\|^2 = 1 \end{array} \right\} \xrightarrow{\hat{a}=0} \left. \begin{array}{l} x(m+\lambda) = 0 \\ \|x\|^2 = 1 \end{array} \right\}$$

Entonces si se cumple que $\lambda = -m$

\Rightarrow todo x de módulo 1 cumple las condiciones. Entonces toda punto es candidato a mínima

Veamos que si $\hat{a}=0$ entonces la función es constante sujeta a los $\|x\|=1$

$$\begin{aligned} f(x) &= \sum_{j=1}^m \|x - a_j\|^2 = m\|x\|^2 + \sum_{j=1}^m \|a_j\|^2 - 2x^T \sum_{j=1}^m a_j \\ &= m\|x\|^2 + \sum_{j=1}^m \|a_j\|^2 \end{aligned} \quad \hat{a}=0$$

De esta forma se tiene que

$$f(x) = m + \sum_{j=1}^m \|a_j\|^2 \quad \text{si } \|x\|=1$$

Por lo tanto, todo punto que cumple la restricción es mínimo

Ejercicio 4

$$a) \begin{cases} \min_{x,y,z} & \frac{1}{2} \|Ax - \alpha\|^2 + \frac{1}{2} \|Bx - \beta\|^2 + \frac{1}{2} \|Cz - \gamma\|^2 \\ \text{st.} & x = y \\ & x = z \end{cases}$$

El lagrangeano del problema es:

$$L(x, y, z, \lambda) = \frac{1}{2} \|Ax - \alpha\|^2 + \frac{1}{2} \|By - \beta\|^2 + \frac{1}{2} \|Cz - \gamma\|^2 + \lambda_1(x - y) + \lambda_2(x - z)$$

Las condiciones que se derivan de $\nabla L = 0$ son:

$$\begin{cases} A^T(Ax - \alpha) + \lambda_1 + \lambda_2 = 0 \\ B^T(By - \beta) - \lambda_1 = 0 \\ C^T(Cz - \gamma) - \lambda_2 = 0 \\ x = y \\ x = z \end{cases}$$

⇒ Se deberá cumplir:

$$A^T(Ax - \alpha) + B^T(Bx - \beta) + C^T(Cx - \gamma) = 0$$

$$\Rightarrow \boxed{\bar{x} = \bar{y} = \bar{z} = (A^T A + B^T B + C^T C)^{-1} (A^T \alpha + B^T \beta + C^T \gamma)}$$

b) Sea $w = [x, y, z]$ y

$$\begin{cases} \min_{w \in \mathbb{R}^{3n}} \frac{1}{2} \|Dw - \delta\|^2 \\ \text{st } Hw = 0 \end{cases} \quad \text{con } \delta = [\alpha, \beta, \gamma]$$

* Primeras veamos que H es:

$$H = \begin{pmatrix} \text{Id} & -\text{Id} & 0 \\ \text{Id} & 0 & -\text{Id} \end{pmatrix} \quad \text{con } H \in \mathcal{M}^{2n \times 3n}$$

Se tiene que $Hw = H \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x - y \\ x - z \end{pmatrix}$ por lo que la restricción es equivalente

* Ahora veamos que D es:

$$D = \begin{pmatrix} A & 0 & 0 \\ 0 & B & 0 \\ 0 & 0 & C \end{pmatrix} \quad \text{con } D \in \mathcal{M}^{3n \times 3n}$$

Ver que $\frac{1}{2} \|Dw - \delta\|^2 = \frac{1}{2} \left\| \begin{pmatrix} Ax \\ By \\ Cz \end{pmatrix} - \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} \right\|^2$

Pr $= \frac{1}{2} \left(\sum_i (Ax)_i - \alpha_i)^2 + \sum_i (By)_i - \beta_i)^2 + \sum_i (Cz)_i - \gamma_i)^2 \right)$
 $= \frac{1}{2} (\|Ax - \alpha\|^2 + \|By - \beta\|^2 + \|Cz - \gamma\|^2)$

c) El Lagrangeano es:

$$L(w, \lambda) = \frac{1}{2} \|Dw - \delta\|^2 + \lambda^T Hw$$

Su gradiente:

$$\nabla L_w(w, \lambda) = D^T(Dw - \delta) + H^T \lambda$$

$$\nabla L_\lambda(w, \lambda) = Hw$$

Entonces, $\nabla L(\bar{w}, \bar{\lambda}) = 0 \Leftrightarrow \begin{cases} D^T(D\bar{w} - \delta) + H^T \bar{\lambda} = 0 & (1) \\ H\bar{w} = 0 & (2) \end{cases}$

Despejamos \bar{w} de (1), $(D^T D)^{-1}$

$$\Rightarrow D\bar{w} - \delta = -(D^T)^{-1} H^T \bar{\lambda} \Rightarrow \bar{w} = D^{-1} \delta - \underbrace{D^{-1} (D^T)^{-1}}_{(D^T D)^{-1}} H^T \bar{\lambda}$$

$$\Rightarrow \bar{w} = D^{-1} \delta - (D^T D)^{-1} H^T \bar{\lambda}$$

Introducimos \bar{w} en (2)

$$\Rightarrow H(D^{-1} \delta - (D^T D)^{-1} H^T \bar{\lambda}) = 0$$

$$\Rightarrow \boxed{\bar{\lambda} = (H(D^T D)^{-1} H^T)^{-1} H D^{-1} \delta}$$

Tenemos que \bar{w} será

$$\bar{w} = D^{-1} \delta - (D^T D)^{-1} H^T (H(D^T D)^{-1} H^T)^{-1} H D^{-1} \delta$$

d) El Lagrangeano aumentado (L_c) es:

$$L_c(w, \lambda) = \frac{1}{2} \|Dw - \delta\|^2 + \lambda^T Hw + \frac{\gamma}{2} \|Hw\|^2$$

Para calcular el mínimo, calculamos ∇L_c y lo igualamos a 0

$$\Rightarrow \nabla L_c = D^T(Dw - \delta) + H^T\lambda + \gamma H^THw$$

$$\nabla L_c = 0 \Leftrightarrow (D^TD + \gamma H^TH)w = D^T\delta - H^T\lambda$$

$$\Rightarrow \boxed{\bar{w} = (D^TD + \gamma H^TH)^{-1}(D^T\delta - H^T\lambda)}$$

Implementación

Al resolver el problema de forma exacta se obtiene la siguiente solución:

$$\mathbf{x}^* = \begin{bmatrix} -0.45209767 \\ -0.11645923 \\ -0.00416928 \\ -0.06615063 \\ 0.15325308 \\ 0.12561526 \\ -0.0518167 \\ -0.00062787 \\ -0.04588603 \\ 0.00636417 \end{bmatrix}$$

La siguiente gráfica corresponde al error de cada uno de los métodos respecto al óptimo teórico (x^*), es decir se grafica $\frac{\|x^k - x^*\|_2}{\|x^*\|_2}$ en escala vertical logarítmica.




Figure 1: Evolución del error respecto al valor óptimo (x^*) en cada uno de los 5 métodos propuestos

A primera vista esta gráfica puede parecer incorrecta ya que las curvas no terminan, pero esto se debe a que algoritmo finaliza si $\frac{\|w^k - w^{k-1}\|}{\|w^k\|} < 1e-8$ o si se alcanzan las 100 iteraciones. En la tabla 1 se muestra en una tabla la cantidad de iteraciones requeridas para cada uno de los métodos implementados.

Método	Numero de Iteraciones
Penalización cuadrática $\lambda = \lambda^*, \tau = \tau_0 2^k$	1
Penalización cuadrática $\lambda = 0, \tau = \tau_0 2^k$	40
Multiplicadores $\lambda^0 = 0, \tau = 10\tau_0, \lambda^k = \lambda^{k-1} + \tau Hw$	100
Multiplicadores $\lambda^0 = 0, \tau = 1000\tau_0, \lambda^k = \lambda^{k-1} + \tau Hw$	100
Combinado $\lambda^0 = 0, \lambda^k = \lambda^{k-1} + \tau^k Hw, \tau = \tau_0 2^k$	22

Table 1: Iteraciones requeridas por cada uno de los métodos.

A partir de la gráfica y la tabla se aprecia que la elección el λ en el método de penalización cuadrática es clave para mejorar la tasa de convergencia, cuando se usa el lambda óptimo el método converge inmediatamente, mientras que si esta elección no es exacta ($\lambda = 0$) se tarda 40 iteraciones.

En cuanto los métodos de multiplicadores, ocurrió que el algoritmo no converge en menos de 100 iteraciones para los τ propuestos en la letra. Dado que mientras se implementaba se observó que a mayor valor de τ se tenía mayor velocidad, surgió la curiosidad de si el aumentar aun mas el τ , por ejemplo a $100.000\tau_0$ se obtendrá una convergencia mayor. Al probar lo anterior se observó (ver Figura 1) que para este nuevo valor de τ el algoritmo converge rápidamente (11 iteraciones) al punto óptimo. Se concluye que valor de τ es relevante para el método anterior.

En ultimo lugar se tiene el método combinado, el cual utiliza las virtudes de ambos métodos. Por un lado se aprovecha de la buena actualización de λ que realiza el método de los multiplicadores, y por otro lado utiliza un valor de τ con aumento exponencial que es la clave del método de penalización cuadrática. De esta forma se obtiene una velocidad de convergencia superior a tener uno de los dos parámetros fijos.

A continuación, se presentan los puntos obtenidos por cada método (el subíndice se corresponde con el orden en el que han sido presentado previamente).

$$x_1 = \begin{bmatrix} -0.45209767 \\ -0.11645923 \\ -0.00416928 \\ -0.06615063 \\ 0.15325308 \\ 0.12561526 \\ -0.0518167 \\ -0.00062787 \\ -0.04588603 \\ 0.00636417 \end{bmatrix}, x_2 = \begin{bmatrix} -0.45209767 \\ -0.11645923 \\ -0.00416928 \\ -0.06615063 \\ 0.15325307 \\ 0.12561526 \\ -0.0518167 \\ -0.00062787 \\ -0.04588603 \\ 0.00636417 \end{bmatrix}, x_3 = \begin{bmatrix} 0.49428732 \\ -0.359564 \\ -0.86401806 \\ -0.27124434 \\ -0.03539417 \\ 0.17024413 \\ -0.51730138 \\ 0.54697099 \\ 0.06391845 \\ -0.08557211 \end{bmatrix}$$

$$x_4 = \begin{bmatrix} -0.45180941 \\ -0.11718768 \\ -0.00445706 \\ -0.06611046 \\ 0.15273706 \\ 0.1260817 \\ -0.05162811 \\ -0.0011988 \\ -0.04811751 \\ 0.00630212 \end{bmatrix}, x_5 = \begin{bmatrix} -0.45209767 \\ -0.11645923 \\ -0.00416928 \\ -0.06615063 \\ 0.15325308 \\ 0.12561526 \\ -0.0518167 \\ -0.00062787 \\ -0.04588603 \\ 0.00636417 \end{bmatrix}$$

Lo importante a destacar de los puntos obtenidos es que en todos los casos en el que el algoritmo llega a su condición de parada (en otras palabras, converge) debido a que $\epsilon < 1 \times 10^{-8}$ se obtiene el punto óptimo x^* .

Esto era de esperar ya que estamos en las hipótesis de la **Proposición 1** dada en el teórico, ya que en todos los casos se toman $\{\lambda^k\}$ acotados y $\{c^k\}$ crecientes tendiendo a infinito. Por lo tanto, al cumplirse las hipótesis, teóricamente se tiene que todo punto límite de la sucesión x^k es un mínimo del problema original. Se observa que lo anterior se verifica de forma práctica.

Código

Los fragmentos de código relevantes para el método combinado se encuentra a continuación. En caso de requerir más detalle, junto con este *PDF* se adjunta el archivo *code.py* que contiene la totalidad de código fuente.

```
import numpy as np

def calc_x_from_w(w):
    xyz = np.reshape(w, (3,-1))
    x = np.mean(xyz, axis=0)
    return x

def calc_error(wk, wk_1):
    error = np.linalg.norm(wk - wk_1) / np.linalg.norm(wk)
    return error

def print_info(k, xk):
    print('El número de iteraciones es: ', k, '\n')
    print('El punto al que converge es: ', xk[k])
    print('-'*50, '\n\n')

def w_lagrangeando_aumentado(D, H, S, tauk, lambda_ref):
    return np.linalg.inv(D.T@D+tauk*H.T@H) @ (D.T@S - H.T@lambda_ref)

def metodo_combinado(D, H, S, tau, epsilon=1e-8, MAX_ITER=100,
                     verbose=True):
    xk = list()
    ek = list()
    lambda_k = np.zeros(H.shape[0])
    for k in range(MAX_ITER):
        tauk = tau(k)
        lambda_ref = lambda_k
        w_ = w_lagrangeando_aumentado(D, H, S, tauk, lambda_ref)
        xk.append(calc_x_from_w(w_))
        if k>0:
            ek.append(error:=calc_error(xk[k], xk[k-1]))
        if k>0 and error<epsilon:
            break
        lambda_k += tauk*H@w_

    if verbose:
        print_info(k, xk)

    xk = np.array(xk)
    return xk, ek
```



```
xk_h, ek_h = metodo_combinado(D, H, S, lambda k:2**k*tau0)
```